

Patrones lingüísticos

【64†embed_image】 *Figura:* Diagrama MDS de Zaitsev et al. (2025) que agrupa estadísticamente textos por sus rasgos estilométricos. Se aprecia que los textos generados por IA (colores distintos para GPT-4, Claude, etc.) forman clústeres separados de los textos humanos, e incluso que Llama 3.1 (puntos morados) destaca como caso particular 【15†L189-L194】. Esto sugiere que atributos textuales (distribuciones de palabras, construcción sintáctica) generan “huellas” cuantificables. A partir de la literatura reciente, se han identificado diversos rasgos lingüísticos asociados a textos de LLM:

- **Frecuencia de categorías léxicas:** Los textos de IA tienden a usar más sustantivos, verbos, preposiciones y auxiliares que los humanos 【32†L154-L161】. En contraste, suelen emplear relativamente menos adjetivos calificativos y modismos. Este patrón puede reflejar un estilo informativo y uniforme.
- **Uso de conectores y marcadores discursivos:** Se observa un mayor uso de “palabras de enlace” (conjunciones y transiciones como *sin embargo*, *además*, *por lo tanto*) en textos de LLM 【32†L154-L161】. Ello genera una cohesión explícita y un estilo muy ordenado, casi monótono.
- **Diversidad y riqueza léxica:** Los LLM suelen tener menor diversidad léxica en segmentos cortos. Métricas estilométricas como la tasa tipo-token (TTR), el conteo de hapax legómenos o el número de palabras únicas tienden a ser menores en textos de IA 【9†L158-L166】. Dicho de otro modo, las IA reutilizan con más frecuencia las mismas palabras y construcciones que un humano, limitando la variedad estilística.
- **Palabras atenuadoras vs. intensificadoras:** Se ha documentado que los textos de IA usan muchos **atenuadores** (hedges) como “*puede*”, “*posiblemente*”, “*parcialmente*”, y casi no emplean **reforzadores** enfáticos como “*definitivamente*”, “*evidentemente*” 【44†L42-L49】. Shalevsky (2024) observó que, p. ej., ChatGPT 3.5 usa “*may*” (“*puede*”) con mucha frecuencia y prácticamente nunca “*clearly/definitely*” 【44†L42-L49】 , lo que les da un tono más cauteloso y neutral que en la escritura humana.
- **Pronombres y referencias:** En general, los LLM tienden a usar menos pronombres de primera persona y referencias contextuales explícitas (aunque esto varía con el prompt). Por ejemplo, StyloAI incluye la frecuencia de pronombres de primera persona como rasgo distintivo 【10†L261-L264】. En muchos casos, ChatGPT evita hablar en primera persona a menos que se lo pida.
- **Voz activa/pasiva y construcciones:** Algunas investigaciones indican diferencias sutiles en la preferencia de voz gramatical. Omar Polat et al. (2026) reportaron que los textos de IA usan ligeramente más voz pasiva y construcciones subordinadas, aunque estos efectos son débiles y dependientes del género textual 【32†L154-L161】.
- **Estructuras sintácticas:** Los LLM exhiben ciertas recurrencias: pueden repetir fórmulas sintácticas completas con variantes mínimas, mantener paralelismos en listados y evitar construcciones gramaticales muy creativas. Por ejemplo, se ha notado que los modelos generan oraciones largas con cláusulas encadenadas, poca fragmentación y baja profundización sintáctica. No obstante, estas tendencias son más evidentes en modelos antiguos y pueden reducirse con prompting.
- **Puntuación:** Los textos de IA tienden a usar puntuación convencional de manera «perfecta»: pocos errores y distribución típica (ej., más comas y puntos correctamente ubicados). Estudios de Shijaku & Canhasi (2023) incluyen el recuento de comas, puntos y otros signos como características, confirmando que las IA suelen tener una puntuación muy regular 【9†L158-L166】 【53†L410-L418】.

- **Concreción vs. abstracción:** Hay indicios de que los LLM usan más términos abstractos o genéricos (fuerte, robusto, significativo) y menos adjetivos sensoriales o ejemplificativos. Este efecto aún falta cuantificar ampliamente.
- **Legibilidad y formalidad:** En promedio, los textos generados por IA alcanzan valores de legibilidad similares a los humanos (similares índices Flesch o Gunning Fog) [32†L158-L162] . Sin embargo, su tono suele ser más formal, enciclopédico y preciso. ChatGPT suele explicar conceptos con exceso de detalles o redundancia (contextualización innecesaria), reflejando un sesgo explicativo desarrollado en el entrenamiento. Estas características discursivas (tono didáctico y formal) son difíciles de medir automáticamente, pero son señaladas en estudios de caso como rasgos estilísticos de LLM.

Patrones retóricos y discursivos

- **Estructura ordenada y simétrica:** Los modelos LLM frecuentemente organizan el texto con introducción clara, desarrollo por puntos o párrafos bien balanceados, y conclusiones explícitas. Tienden a presentar ideas siguiendo una estructura lógica clara: tesis, argumentos, ejemplos, contraargumentos y conclusión. A menudo utilizan enumeraciones numeradas o con viñetas (si se lo indica el prompt) y dividen el contenido en categorías predecibles (por ejemplo, “ventajas vs desventajas”). Esta organización rígida contrasta con la fluidez creativa del discurso humano, pero es más una observación anecdótica que una regla universal.
- **Transiciones y conectores discursivos:** Como se mencionó, las IA usan abundantes conectores (“además”, “por ejemplo”, “sin embargo”), lo que resulta en transiciones suaves pero a veces excesivamente redundantes. Proporcionan un «camino» discursivo muy explícito entre ideas, mientras que los humanos podrían omitir algunos enlaces por implicación.
- **Expresión de grados de certeza:** Las máquinas utilizan sistemáticamente expresiones de posibilidad o duda (ej. “puede ser que...”, “generalmente”), y rara vez afirmaciones categóricas. Evitan términos absolutos y suelen matizar sus afirmaciones para «cubrirse», lo que refleja el entrenamiento para no declarar verdades tajantes sin respaldo [44†L42-L49] .
- **Tono diplomático y neutralidad:** Los textos de IA tienden a ser muy imparciales y educados. Se han observado fórmulas de cortesía y bajo uso de jerga coloquial o voz personal. Por ejemplo, Shalevska encuentra cero usos de reforzadores como “obviamente” o “definitivamente” en textos de IA [44†L42-L49] , lo cual refuerza un tono moderado y “políticamente correcto”. En general, los LLM evitan temas polémicos o juicios de valor (si no se les solicita), manteniéndose neutrales.
- **Contextualización excesiva:** Los LLM suelen reexplicar hechos o definiciones que un escritor humano daría por conocidas. Por ejemplo, un texto de IA a veces define términos básicos antes de usarlos, o coloca oraciones de transición muy explicativas. Este “exceso” de contexto es una señal pragmática sutil: la máquina procura ser clara y autocontenida, a diferencia de un autor experto que omitiría dichas explicaciones.
- **Simetría y balance:** En muchos casos, ChatGPT presenta un estilo equilibrado: si ofrece argumentos a favor, también tiende a ofrecer contraargumentos, o viceversa. Se observa una preferencia por el equilibrio retórico y evitar posiciones extremas. Aunque no existe una métrica única que lo mida, revisiones de estilo indican que las IA presentan simetrías en la estructura argumentativa, evitando contenidos unilateralmente agresivos.

Señales estadísticas y cuantificables

- **Perplejidad y log-verosimilitud:** Métricas clásicas de probabilidad de secuencia. La perplejidad (inversa de la probabilidad promedio por token) se usa desde GLTR (2019) hasta GPTZero. GPTZero específicamente utiliza la perplejidad media y máxima por frase como señal [4†L160-

L163] . En general, textos de IA suelen tener *perplejidad más baja* con respecto a su propio modelo (más predecibles), aunque esto no garantiza detectabilidad por sí solo.

- **Burstiness (variación de longitud):** GPTZero también mide la variabilidad en la longitud de las frases. Se ha sugerido que los humanos escriben con más “retoños” lingüísticos (picos y valles en duración), mientras las IA producen frases de longitud más uniforme [4†L160-L163] . Sin embargo, estudios recientes indican que la burstiness no discrimina consistentemente entre texto humano y de IA en todas las condiciones.
- **Entropía y curvatura de probabilidad:** DetectGPT (2023) introdujo una métrica basada en la curvatura del logaritmo de probabilidad (segunda derivada). Hallaron que el texto de LLM suele encontrarse en zonas de **curvatura negativa** de la función de probabilidad del modelo, algo menos común en texto humano [37†L27-L34] . Este indicador (precisamente la desviación en la probabilidad al perturbar el texto) es novedoso y funciona sin entrenamiento adicional, pero requiere acceso al modelo generador (no es una métrica de texto plano).
- **Distribuciones de etiquetas gramaticales (POS):** Cuenta de categorías gramaticales. Omar Polat et al. (2026) reportan que los textos de IA tienden a tener más *sustantivos, verbos, preposiciones* y auxiliares que los humanos [32†L154-L161] . En contraste, los humanos usarían relativamente más adjetivos y estructuras varias. Este patrón puede medirse rápidamente con un POS-tagger.
- **Conteo de palabras funcionales:** Medir la frecuencia de stopwords (artículos, preposiciones, pronombres) da señales indirectas de estilo. Por ejemplo, StyloAI incluye el recuento de stopwords como feature [53†L482-L491] . En ciertos estudios, el uso de partículas y pronombres en japonés distinguió IA de humanos [16†L7-L10] , y es plausible que en español la distribución de palabras de función sea también informativa (p.ej. uso de “de”, “la”, “que”).
- **Diversidad léxica:** Métricas tipo tipo-token ratio (TTR), conteo de palabras únicas o hapax legómenos permiten cuantificar variación léxica [9†L158-L166] . Generalmente, humanos tienen mayor TTR en textos equivalentes, mientras IA repite vocabulario más uniformemente. La diferencia en riqueza léxica es consistente con la menor “creatividad” estadística de las IA.
- **Longitud media de frases/párrafos:** Estadísticas de nivel de texto (profundidad sintáctica media, número medio de palabras por oración o párrafo, desviaciones típicas) aparecen en detectores [53†L497-L506] . Por ejemplo, LLM tienden a producir párrafos de longitud más homogénea y oraciones relativamente más largas y compuestas. Shijaku & Canhasi incluyen estas medidas en su análisis (wordsPerSentence, sentencesPerParagraph, etc.) [53†L497-L506] .
- **Medidas de legibilidad:** Índices como Flesch Reading Ease o Gunning Fog se han utilizado [32†L158-L162] . Aunque en general los textos de IA alcanzan rangos legibles cercanos a textos formales humanos, a veces resultan ligeramente más complejos (Flesch Kincaid un poco mayor) [53†L445-L448] . Estos índices miden cantidad de sílabas y sintagmas, reflejando que las IA usan frases bien estructuradas.
- **Repetición de n-gramas:** Un clásico: detectar tramos repetidos de texto. Algunas IA pueden repetir frases o estructuras (sobre todo sin “anti-repetición”). Por ello, se analizan frecuencias de n-gramas largos. StyloAI introduce métricas como “unicidad de bigramas/trigramas” y el uso de embeddings (vistas semánticas) para captar repetición [53†L469-L473] . En particular, se calculó la distancia promedio entre vectores SBERT de frases sucesivas: textos de IA mostraron distancias menores (más frases similares) que textos humanos [53†L469-L473] .
- **Distancias en espacios vectoriales:** Métodos más avanzados usan embeddings de oraciones o documentos (p. ej. BERT) para ver qué tan cerca quedan semánticamente segmentos consecutivos. Como señala Shijaku et al., “el texto de IA a menudo contiene frases repetitivas o patrones” y midieron la cohesión semántica [53†L469-L473] . Además, se pueden comparar tensores (output de transformadores) de documentos completos para medir la uniformidad estilística entre muestras de modelo.

- **Clasificadores supervisados:** En la práctica, muchas “huellas” se aprenden con modelos de machine learning. Por ejemplo, un clasificador XGBoost o SVM entrenado sobre características lingüísticas (n-gramas, TF-IDF, POS, léxico) ha logrado ~82-84% de precisión en datos generales [32†L163-L167] . Modelos de transformer finos (DistilBERT, RoBERTa) pueden superar 90% [25†L46-L53] , incluso 99% en tareas concretas [32†L174-L182] . Sin embargo, dichos resultados dependen fuertemente del conjunto de entrenamiento (género, tópico, longitud), tal como documenta Shijaku et al. (los RF fueron robustos, SVM sensibles al tema [72†L166-L174]).
- **Marcado digital (“watermarking”):** Más allá del texto en sí, se han propuesto huellas criptográficas. Por ejemplo, se sugiere que los generadores de IA inserten un patrón sutil en la elección de tokens (p. ej. favorecer sistemáticamente ciertos sinónimos) para facilitar la detección [54†L165-L172] . Anthropic ya ha anunciado que sus futuros modelos (Claude) incluirán marcas de agua en el texto. Sin embargo, estas técnicas dependen del conocimiento secreto de la regla, y aún no hay implementaciones públicas verificables.

Huellas por familia de modelos

- **GPT (OpenAI, ChatGPT):** La mayor parte de la literatura se ha centrado en la línea GPT (GPT-2 a GPT-4o). Estudios como Shijaku et al. (2023) han detectado textos de ChatGPT 3.5-4 con altísima precisión ($\approx 98\%$ usando XGBoost) [72†L177-L182] . DetectGPT (2023) logró AUROC ≈ 0.95 discriminando textos generados por GPT-NeoX (20B) [37†L27-L34] . Estas señales (diversidad léxica, patrones de repetición, curvatura de probabilidad) aparecen en todas las generaciones GPT estudiadas. Se sabe que GPT-4 (con RLHF) produce textos aún más “humanos” que GPT-3.5, lo cual tiende a **atenuar** algunas señales (por ejemplo, menos errores y menos respuestas de disculpa automáticas). No obstante, la investigación actual muestra que siguen existiendo diferencias estadísticamente consistentes entre GPT-4 y escritos humanos del mismo nivel educativo.
- **Claude (Anthropic) y Gemini (Google):** Hasta la fecha hay poca bibliografía específica sobre estos modelos en comparación con GPT. Se presume que, dado su entrenamiento similar (con Llama o sparsity, RLHF, etc.), comparten la mayoría de huellas de GPT. Por ejemplo, el estudio de Zaitsev et al. (2025) comparó siete LLM (incluyendo ChatGPT, Claude3.5, Gemini, Copilot y Llama3.1) y no encontró rasgos estilísticos distintivos propios de cada nombre, salvo el caso especial de Llama3.1 [15†L189-L194] . En la práctica, esto sugiere que **los detectores basados en estilo tienden a generalizar bien entre familias similares** (e.g. GPT vs Claude) siempre que se entrene con suficiente variedad.
- **Llama (Meta) y Mistral (Mistral AI):** Zaitsev et al. resaltan que **Llama 3.1** mostró un estilo claramente distinto de GPT/Gemini/Claude [15†L189-L194] . Esto podría deberse a diferencias en tokenización o datos de entrenamiento. No hay evidencias amplias sobre Mistral o Llama 2, pero se espera que modelos similares de código abierto compartan muchas huellas con las GPT. Aún así, se debe tener precaución: una huella que funcione para Llama 3.1 podría no aplicarse a GPT-4, y viceversa. Estudios de *model attribution* han comenzado a proponer identificadores *fuzzy* que permiten (en teoría) asignar un texto a una “familia” de modelos, pero esas técnicas son aún exploratorias.
- **Modelos especializados (DeepSeek, Qwen, Cohere, etc.):** No hay literatura formal que liste señales exclusivas para estos. Suponemos que las diferencias residirán principalmente en sus bases de entrenamiento (por ejemplo, un modelo entrenado para código tendrá léxico técnico inusual) o en métodos de alineamiento. Sin embargo, **no existe una “huella universal” de IA:** cada modelo puede manifestar sutilezas propias, y muchas de las señales más fuertes solo surgen porque varios modelos LLM comparten arquitectura y objetivos.

- **Alineamiento y fine-tuning (RLHF/RLAIF):** Los procesos de afinamiento cambian el estilo base. Por ejemplo, GPT-4 con RLHF evita respuestas dañinas y añade explicaciones de precaución, lo que podría introducir sesgos (más formulaciones retóricas, disculpas, etc.). Aún así, la mayoría de las huellas estudiadas (e.g. distribución de POS, diversidad léxica) **persiste** tras el alineamiento, ya que proviene del modelo base. En cambio, señales superficiales (como evitar responder a ciertas preguntas) **no sirven** de forma general, porque dependen del contexto del prompt.
- **Detección de modelos específicos:** Algunos trabajos recientes de *fingerprinting* y *attribution* buscan asignar textos a modelos particulares. Aún no hay benchmarks consolidados. En principio, características estilométricas o probabilísticas podrían permitir no solo distinguir IA/humano, sino también inferir la familia/modelo responsable. Por ejemplo, Arnaudo et al. (2023) y Huang et al. (2025) exploran “firmas difusas” de LLM, pero estos métodos están en desarrollo. En la práctica, cualquier atribución a un modelo concreto debe tomarse con cautela: muchas señales están correlacionadas con el estilo general del modelo (e.g. GPT vs Llama) más que con detalles finos.

Evolución temporal

- **Modelos tempranos (RNNs, LSTM, GPT-1/2):** En fases iniciales se detectaban señales muy obvias: repeticiones monótonas, errores tipográficos sistemáticos, oraciones sin cohesión completa. Herramientas como GLTR (2019) mostraban que el texto de GPT-2 tenía una distribución de probabilidad muy «picuda» (pocos tokens improbables), mientras los humanos usaban vocabulario más variado.
- **GPT-3 y ChatGPT 3.5 (2020–2022):** Estos modelos ya eran mucho más coherentes. Empezaron a automatizarse comprobaciones como evitar dar consejos peligrosos o reconocer que eran IA, pero estos no dejan marcadores fiables. Sin embargo, se observaba que mantenían menos errores gramaticales y un vocabulario muy pulido. Los estudios de 2023 mostraron que era posible detectar ChatGPT-3.5 con alta precisión usando stylometry y ML clásico [72†L177-L182]. También se empezó a debatir (e.g. Burrows’ Delta) la robustez: un fenómeno recurrente es que la IA produce un “promedio” estilístico común a muchos temas, en contraposición a la individualidad humana [66†L1097-L1102].
- **GPT-4 y modelos 2023–2024:** Las versiones más recientes (GPT-4, Claude 3, Gemini, Mistral 7B) han reducido ciertas diferencias. Su lenguaje es más variado (mayor *burstiness* de verdad) y se asemeja aún más al humano. Por ejemplo, Zou (2023) reporta que la dependencia de *perplexity* ya no es fiable con estos modelos, pues su escritura supera en coherencia a muchos autores humanos informales [54†L139-L148]. Señales que funcionaban bien con ChatGPT-3.5 (e.g. ciertas colocaciones de palabras funcionales) **se debilitan** con GPT-4: los modelos han aprendido a diversificar esas formas. En resumen, **las huellas varían con la generación del modelo**: las más antiguas (repeticiones literales, errores fáciles de memorizar) han desaparecido, y las nuevas son más sutiles.
- **Cambios por alineamiento:** Con cada generación se intensificó el RLHF/RLAIF, haciendo el estilo más pulido pero también más homogéneo. Esto ha reducido la “detectabilidad clásica” (p.ej. GPT-4 casi no produce frases incoherentes). En contraste, **ha aumentado la uniformidad estadística**: las IA más nuevas son “máquinas de promedios” aún más que antes [66†L1097-L1102]. Por ello, aunque es más difícil distinguir frase por frase, la ausencia de variabilidad estilística en textos largos sigue siendo una señal emergente.
- **Señales históricas superadas:** Muchos consejos virales de 2022 (“evita repeticiones, no uses demasiados adjetivos, no empieces párrafos con conectores”) han sido superados. Estudios recientes indican que dichas prácticas no son exclusivos de IA: escritores humanos formales a menudo hacen lo mismo. En particular, la afirmación “*Los textos de IA no cometen errores*”

tipográficos” fue cierta con GPT-3, pero ahora las IA sí pueden introducir errores deliberadamente (si se les pide) o evitarlo gracias a correctores incorporados. En suma, **lo que hoy sirve de señal puede perder peso con el avance de los modelos.**

Influencia del *prompting* y configuración

- **Estilo e instrucciones:** Cambiar la instrucción de generación puede transformar radicalmente la “huella”. Por ejemplo, pedir *“escribe como si fueras informal/joven”* o *“usa expresiones coloquiales y abreviaturas”* llevará a la IA a imitar patrones humanos, reduciendo muchas señales de escritura estándar. Diversos experimentos (Zou 2023) demuestran que frases simples de “prompt engineering” (p.ej. *“eleva el texto con lenguaje literario”*) engañan detectores basados en *perplexity* [54†L152-L160]. En consecuencia, señales superficiales como vocabulario formal o falta de errores se pierden fácilmente si se varía el prompt.
- **Temperatura y aleatoriedad:** Ajustar parámetros de generación afecta las métricas. Una temperatura más alta produce más variación léxica (mayor *diversidad léxica*), lo cual puede “simular” estilo humano más caótico. Sin embargo, una temperatura excesiva puede disminuir coherencia semántica, exponiendo otros patrones. En la práctica, las fuentes señalan que alterando temperatura y *top-p* se puede neutralizar parcialmente señales de uniformidad; pero ninguna es infalible: la IA sigue tendiendo a respuestas formales por defecto.
- **Instrucción de estilo personal:** Decirle a la IA que escriba “con errores” o “con personalidad” puede introducir imperfecciones visibles (fallos gramaticales o coloquialismos). Esto efectivamente reduce la detectabilidad: un estudio de Zou (Stanford) muestra que incluso humanos no nativos, con menor sofisticación lingüística, confunden a los detectores actuales [54†L139-L148]. Imitar un autor real o dialecto específico también borra algunos patrones genéricos de IA. En resumen, **muchas señales lingüísticas típicas de IA (formalidad extrema, sin coloquialismos) son frágiles al prompting humano**, mientras que las medidas profundas (curvatura de probabilidad, sesgo estadístico) son más robustas.
- **Generación multi-paso o reescritura:** Estrategias como “escribir primero y luego reescribir” o “resumir en pasos” pueden disimular huellas. Cada iteración por la IA puede suavizar patrones inusuales. También, traducir un texto de IA a otro idioma y volver a traducirlo puede introducir ruidos adicionales. No hay estudios publicados amplios sobre esto, pero se infiere que **todo grado de post-procesamiento humano (correcciones, paráfrasis) diluye las señales originales de la IA.**

Textos híbridos (edición humana + IA)

- **Intervención humana ligera:** Si un humano simplemente corrige ortografía y redacción mínima (p.ej. añade un sinónimo o corrige gramática), la mayoría de las huellas persisten: las estructuras sintácticas y la organización general aún provienen del modelo. Dado que los detectores suelen examinar patrones generales, una corrección leve raramente engaña completamente a un modelo entrenado en la misma familia de IA.
- **Reescritura parcial:** Si un humano reescribe segmentos (cambiar frases, variar vocabulario en partes), los rasgos de estilo mixto emergen. Algunas señales sobreviven (como la “voz media” homogénea en pasajes sin tocar) pero otras se diluyen (p.ej. se rompe la consistencia de léxico repetido). A medida que aumenta la porción escrita por humanos, la señal de IA va menguando. En general, **no se han encontrado “huellas de IA” que sean inmutables ante cualquier edición**; cada acto humano (paráfrasis, traducción, corrección estilística) borra parte del perfil original.
- **Generación + edición extensa:** En casos donde el humano reformula intensamente o intercala sus propios fragmentos, el texto resultante parece más humano. Estudios destacan que los

detectores suelen fallar en este escenario mixto: el texto final hereda inconsistencias típicas de escritura humana (p.ej. voz narrativa variable) y pierde la uniformidad de la IA. La literatura sugiere (aunque escasamente documentado) que **los detectores comerciales tienen altas tasas de falsos negativos** en textos muy editados o hibridados.

- **Asistencia puntual de IA:** Situaciones en las que la IA solo da ideas o corrige gramática (sin reescribir conceptos) apenas dejan huellas en el texto final. En otras palabras, si un escritor humano utiliza IA solo para pulir, el resultado se aproxima 100% al estilo humano.
- **Edición adversarial:** Actividades deliberadas (p.ej. introducir errores, frases incoherentes) pueden ocultar huellas. Por ejemplo, si se añade ortografía incorrecta adrede o se mezcla vocabulario raro, el texto de IA parece menos “puleado” y más humano. Estos trucos reducen la eficacia de señales como “ausencia de errores” o regularidad léxica.

Variación por idioma, género y contexto

- **Idioma:** Casi toda la evidencia está en inglés (y algo en japonés 【16†L7-L10】). Es incierto cuánto se traslada a otros idiomas como el español. Teóricamente, rasgos estadísticos (p.ej. uso de género gramatical, oraciones subordinadas) cambiarán: por ejemplo, las partículas en japonés tienen importancia alta en Zaitsu, mientras en español podría ser relevante el uso de preposiciones o pronombres. En ausencia de estudios específicos en español, debe asumirse que señales como la simplicidad gramatical (número de tiempos verbales distintos, variabilidad de concordancias) serán útiles, pero requerirán revalidación empírica.
- **Variación dialectal:** Los modelos LLM multilingües dominan estilos estándar (por ejemplo, español neutro). Un prompt que les ordene usar dialecto o coloquialismo anula muchas señales formales. Detectores entrenados en español de España detectarán pobremente textos de IA en español latinoamericano sin adaptación.
- **Género textual:** La detectabilidad varía por género. En *ensayos académicos* o textos muy formales, los humanos también usan un estilo objetivo y riguroso, lo que complica distinguirlos de IA (ambos usarán técnicos y referencias). En textos *informales* o creativos, los humanos introducen mayor variabilidad (slang, humor) que la IA estándar. Estudios en inglés han mostrado que detectar IA en textos creativos (ficción) es más difícil que en textos académicos, aunque no hay datos concluyentes. Por ejemplo, Herbold et al. (2023) analizaron ensayos escolares vs AI, encontrando detectores eficaces, pero es posible que en géneros como poesía o narrativa corta las pautas cambien notablemente.
- **Medio/contexto:** En *redes sociales* o chats breves, las IA suelen generar respuestas más largas y detalladas de lo típico en humanos (e.g. explican demasiado). Esto puede ser una señal: un post de 50 palabras muy pulido probablemente provenga de una IA. En *documentación técnica* y *textos jurídicos*, dado que el estilo humano es muy formal y redundante, las IA pasan desapercibidas, pues su estilo pulcro encaja. En *marketing* o *publicidad*, donde el contenido suele intentar persuadir, las IA actuales pierden eficacia, produciendo mensajes muy genéricos; aquí la “falta de creatividad” de la IA puede ser en sí una pista (aunque medible solo con comprensión semántica profunda).
- **Idiomas distintos al inglés:** Algunos estudios multilingües iniciales (por ejemplo, señales en japonés 【15†L189-L194】 【16†L7-L10】) sugieren que muchas de las huellas lingüísticas (uso de palabras funcionales, patrones sintácticos) existen en otros idiomas, pero no con los mismos detalles. En español, podrían considerarse características propias como la concordancia o los tiempos verbales compuestos. Hasta ahora **no se han reportado ni replicado exhaustivamente señales en español**; todo detector basado en inglés sufre un sesgo, como advierte Stanford: etiquetas de idioma o nivel de español (nativo vs no nativo) confundirán detectores de IA 【54†L139-L148】 . Se necesita investigación dedicada para confirmar qué signos de IA sobreviven al pasar al español.

Detectores de texto IA y desempeño

- **Perplejidad como base:** Muchos detectores (GPTZero, otros) usan en fondo *perplejidad* contra el propio modelo. Estudios (Stanford) muestran que esto correlaciona con “sofisticación” del texto [54†L139-L148] . Es decir, un escritor nativo/educado verá su texto marcado como “sophisticated” (baja perplejidad) y los detectores lo asumirán como humano, mientras un texto mal escrito por un humano tendría perplejidad alta y sería etiquetado como IA. Este sesgo induce falsos positivos con autores menos proficientes [54†L139-L148] .
- **Herramientas comerciales vs independientes:** Herramientas populares (Turnitin, Copyleaks, GPTZero) publican sus métodos en general («perplexity + patrones lingüísticos»), pero carecen de evaluación externa independiente. Comparativas recientes muestran que la mayoría de detectores dan falsos positivos frecuentes, especialmente en textos académicos de no nativos [54†L139-L148] . Por ejemplo, Stanford documenta que un detector etiquetó 60% de ensayos TOEFL (escritos por no nativos) como IA [54†L122-L130] . Asimismo, otros estudios (Wang et al. 2023) reportan que las herramientas difieren mucho entre sí: unas tienden a predecir “IA” sistemáticamente, otras “humano” [59†L325-L332] .
- **Medidas de rendimiento:** En la literatura se usan métricas estándar (exactitud, precisión, recall, F1, AUC). La mayoría de artículos de detección reportan F1 altos (>90%) en sus propios datos (generalmente “ensayos escolares vs IA generada”). Por ejemplo, modelos basados en RF alcanzan ~99% de precisión en escenarios controlados [72†L166-L174] . Sin embargo, esos números bajan drásticamente en condiciones realistas (“fuera de distribución”): los detectores sufren alto FPR y FNR cuando se prueban en textos distintos de su entrenamiento (otro tópico, generador, idioma). Pocas referencias publican evaluación externa sólida con métricas calibradas. Un meta-análisis indica que la mayoría de detectores tienen alta precisión *aparente* en muestras construidas artificialmente, pero carecen de robustez real [59†L325-L332] [54†L139-L148] .
- **Robustez frente a modelo no visto:** Estudios muestran que un detector entrenado con muestras de un GPT no generaliza bien a otro. Por ejemplo, un detector afinado en texto de ChatGPT 3.5 podría fallar ante texto de GPT-4 o Llama. Borradores recientes (en revisión) insisten en que es fundamental entrenar con variedad de generadores para evitar sobreajustar a un solo modelo. Hasta ahora, las herramientas comerciales suelen ocultar esta información.
- **Edición y paráfrasis:** Casi todos los detectores probados son muy sensibles a reescrituras: un experimento citado por Zou (2023) demuestra que pedir a la IA reescribir un texto AI como si fuera humano eleva sustancialmente la puntuación de “humanidad” (baja perplejidad) del detector [54†L152-L160] . Esto confirma que ninguna señal lingüística de IA es totalmente inmune a la edición: los desajustes se corrigen y los detectores fallan.
- **Idioma y dominio:** Casi toda la validación de detectores es en inglés, con textos largos y formales. Hay muy pocos resultados confirmados en español u otros lenguajes. Además, los detectores suelen calibrarse con géneros específicos (ensayo académico, periodístico). Como advierte Stanford [54†L139-L148] , al aplicarlos a dominios distintos (p.ej. literario o informal) pierden precisión: pueden etiquetar erróneamente voz narrativa elaborada como “IA” o textos AI muy técnicos como “humano”.
- **Sensibilidad vs. especificidad:** En conjunto, los detectores actuales tienen dos graves limitaciones mostradas por estudios independientes: son demasiado permisivos (bajan falsos negativos solo con mucha edición humana) o demasiado restrictivos (marcan humanos como IA si el texto es simple). Stanford concluye que son “*unreliable and easily gamed*” [54†L139-L148] [54†L152-L160] . A fecha de 2026, no existe un detector con desempeño estable comprobado por pares en entornos reales.
- **Cuestionamiento de resultados comerciales:** Muchas “herramientas” comerciales (p.ej. GPTZero, Turnitin AI detector) hacen afirmaciones de alta fiabilidad, pero estudios académicos

independientes las contradicen. Por ejemplo, Turnitin informa F1 alrededor de 97% en sus documentos (privado), pero publicaciones externas muestran tasas de falso positivo altas cuando se prueban casos reales. En este sentido, **se aconseja buscar estudios revisados o benchmarks públicos antes de confiar en cualquier detector de IA.**

Evidencia académica y discusión crítica

La mayoría de los hallazgos fuertes provienen de estudios con métodos cuantitativos rigurosos (ver referencias arriba). Sin embargo, existen afirmaciones populares sin sustento científico –por ejemplo, la idea de que “*cada texto de IA tiene una huella universal*” es un mito. Las señales descritas dependen fuertemente del modelo, del prompt y del contexto. Estudios como el de Stanford (Zou 2023) recalcan que *lo que los detectores suelen medir es la calidad del lenguaje* (nivel educativo del autor) más que la presencia de IA [54†L139-L148] . Por ello es indispensable:

- Diferenciar **evidencia comprobada** de meras hipótesis o *buzzwords*.
- Verificar si una señal aparece también en textos humanos equivalentes (mismo género, nivel, idioma). Por ejemplo, muchos adultos formales escriben con pocos modismos y errores (similar a la IA), generando falsos positivos.
- Citar siempre métricas e intervalos de efecto: cuando un estudio dice que “IA usa más X”, preguntar *¿cómo de mucho?, ¿en qué corpus y condiciones?* A veces una diferencia es estadísticamente significativa pero pequeña, y no aplicable fuera del laboratorio.
- Buscar replicaciones o contradicciones: hay pistas (como número de errores, uso de primeras personas) que en algunos trabajos aparecieron significativas, pero estudios posteriores (o contextos diferentes) no las confirman.

Robustez y generalización

Cada señal reportada debe evaluarse en **entornos adversos**. Por ejemplo: ¿sigue funcionando la diferencia de diversidad léxica si el modelo recibe un prompt creativo? ¿Se mantiene la falta de reforzadores si se le ordena “sé enfático”? Los pocos análisis de robustez (Zou 2023, estudios de Feng y compañeros) muestran que señales superficiales desaparecen con simples cambios de contexto. Por el contrario, señales *profundas* (distribución de probabilidad, cohesión global) son más resistentes. No obstante:

- Un detector sobreajustado a un conjunto de datos concreto (mismo tópico, autor, modelo) suele fallar fuera de esa distribución [72†L166-L174] [66†L1097-L1102] .
- Traducir un texto a otro idioma rompe casi todas las señales lingüísticas originales; los detectores deben ser multilingües o dan error.
- Los trabajos revisados enfatizan la “homogeneidad” estilística de la IA como clave: un texto muy uniforme en vocabulario y estructura es sospechoso [66†L1097-L1102] . Pero esto también puede ocurrir en textos muy editados humanos (e.g. resumidores automáticos).
- En resumen: ninguna señal es *universalmente* robusta. Es clave combinar múltiples señales y validar el detector en datos diversos para evitar caer en ilusiones de falsa generalidad.

Señales no obvias y perspectivas

Además de los patrones mencionados, algunos investigadores exploran características menos intuitivas:

- **Análisis pragmático:** Coherencia interna muy alta (una IA puede contradecirse menos que un humano, salvo que se le induzca). Consistencia de información a lo largo del texto, o la alineación con datos externos, puede ser una señal forense (si la IA “alucina”, podría dar detalles incorrectos muy confiados).
- **Patrones de puntuación avanzados:** Estudios preliminares buscan diferencias en secuencias inusuales de puntuación (p.ej. uso de dos puntos o punto y coma) que podrían reflejar tokens favorecidos por el decodificador.
- **Tamaño de vocabulario vs entrenamiento:** Una pista investigada es la sobre-representación de las primeras palabras del vocabulario (comunes) en textos de IA. Un posible foco es la entropía de la distribución de frecuencia de palabras comparada con patrones típicos humanos.
- **Características del modelo (tokenización):** Se han sugerido señales basadas en la forma en que el modelo tokeniza: por ejemplo, se han buscado irregularidades en la segmentación de palabras compuestas o rarezas en prefijos/sufijos frecuentes en IA.
- **Análisis forense avanzado:** Hábitos de corrección de un texto (cuántas ediciones haría un humano para suavizarlo) es una línea futura: se podría simular “qué pasaría si este texto lo corrigiera un humano” y medir la distancia al original.
- **Estudios de detección con embeddings:** Algunos trabajos proponen ver cuán “normales” son los embeddings de un texto comparados con los de un corpus humano de referencia, aunque esto requiere recursos grandes.

No se han encontrado señales mágicas adicionales en la literatura revisada más allá de las categorías anteriores. Sin embargo, el campo está en rápida evolución: cada vez surgen nuevas propuestas (por ejemplo, “metadiscursos” o afirmaciones típicas de un modelo) que requieren verificación. Se debe explorar continuamente nuevas métricas estilométricas y de coherencia semántica para detectar IA, siempre contrastando con textos humanos profesionales y variados.

En resumen, la identificación de un texto como “IA” se basa en un conjunto de señales leves y combinadas (estilométricas, léxicas, probabilísticas) más que en un indicador único. Mientras los modelos LLM actuales mantienen patrones globales de uniformidad y complejidad controlada, cada señal por separado presenta excepciones. La evidencia disponible sugiere que las huellas más robustas son las estadísticas profundas (perplejidad/curvatura, diversificación atípica de palabras) y la uniformidad temática [66†L1097-L1102] ; por el contrario, señales fáciles (errores ortográficos, giros discursivos típicos) son altamente manipulables o compartidas con humanos. Por tanto, **la detección confiable requerirá combinar múltiples métricas cuantitativas y adaptarlas a cada contexto**, con la conciencia de que ninguna señal por sí sola garantiza certeza.

Fuentes: Estudios académicos revisados (por ejemplo, Mindner et al. 2023 [53†L410-L418] [53†L422-L425] , StyloAI 2024 [9†L158-L166] , Zaitsev et al. 2025 [15†L189-L194] [66†L1097-L1102] , Shalevska 2024 [44†L42-L49] , Polat et al. 2026 [32†L154-L161] , etc.) y análisis de detectores (Zou 2023 [54†L139-L148] [54†L152-L160] , Wang et al. 2023 [59†L325-L332]) se han utilizado para fundamentar los puntos anteriores. Cada señal aquí descrita cita evidencia empírica o advertencias sobre su fiabilidad según esas fuentes.